

به نام ایزد منان

تمرین دوم درس بازیابی اطلاعات، «روش‌های مبتنی بر شبکه عصبی برای بازیابی اطلاعات»



استاد درس: دکتر ممتازی



پاییز ۱۴۰۱ - دانشکده مهندسی کامپیوتر، دانشگاه صنعتی امیرکبیر

نکاتی در مورد این تمرین که نیاز به توجه و دقت دوستان دارد:

۱- در جدول زیر نحوه اعمال جریمه تاخیر در ارسال تمرین‌ها ذکر شده است.

میزان جریمه	میزان تاخیر (روز)
هر روز ۵٪	۱ الی ۲ روز
هر روز ۱۰٪	۲ الی ۶ روز

در صورتی که بین ۷ تا ۱۴ روز تاخیر داشته باشید، نمره شما از ۵۰٪ محاسبه می‌شود و پس از این بازه با توجه به سایر تمرین‌ها و زمان تحویل، به تمرین ارسالی نمره‌ای تعلق نمی‌گیرد.

۲- هرگونه کپی کردن باعث عدم تعلق نمره به تمامی افراد مشارکت کننده در آن می‌شود.

۳- آخرین مهلت ارسال تمرین، ساعت ۲۳:۵۵ دقیقه روز ۱۰ دی ۱۴۰۱ می‌باشد. این زمان با توجه به جمع‌بندی‌های صورت گرفته، شرایط و با توجه به سایر تمرین‌ها در نظر گرفته شده است و قابل تمدید نمی‌باشد.

۴- دوستان فایل ارسالی خود را به صورت فشرده و به صورت «شماره دانشجویی_HW01» مانند HW01_99131123 نام گذاری کنید. در این فایل باید مواردی نظیر کدها، فایل گزارش و سایر موارد مورد نیاز در هنگام بررسی وجود داشته باشد و صرفاً این فایل در روز ارائه در نظر گرفته می‌شود.

۵- این تمرین دارای تحویل در محیط گوگل میت می‌باشد. زمان آن پس از یک هفته از پایان مهلت تمرین از طریق مودل درس اعلام می‌شود.

۶- زبان برنامه‌نویسی این تمرین می‌تواند پایتون، سی‌پلاس‌پلاس و یا جاوا باشد. (پیشنهاد ما پایتون است).

۷- کدهای خود را به صورت مناسب کامنت گذاری کنید. به صورتی که بتوان حداقل روال اجرا و موارد مورد نیاز را درک کرد.

۸- سعی کنید ابتدا تمامی سوالات و بخش‌ها را مطالعه کنید.

۹- استفاده از هیچ کتابخانه آماده‌ای به جز موارد مطرح شده در تمرین مجاز نمی‌باشد و شما باید تمامی موارد را پیاده‌سازی کنید.

۱۰- در صورت هرگونه سوال یا مشکل می‌توانید با تدریس‌یار درس از طریق ایمیل در ارتباط باشید.

kasra96.d@gmail.com

بخش اول – معرفی دادگان

دادگان^۱ ارائه شده در این تمرین دقیقاً مشابه تمرین اول است. این دادگان شامل ۳ فایل `train`، `validation`، `test` می‌باشد. این دادگان مربوط به تسک *paraphrasing* است که در آن به ازای هر جفت متن سوال، وضعیت *paraphrase* بودن این دو با مقادیر ۰ و ۱ مشخص شده است. هدف ما در این تمرین این است که برای هر یک از `qid1` منحصر به فرد در فایل `test`، ۱۰ سوال *paraphrase* شبیه به آن، از `qid2`های فایل `train` استخراج شود. در واقع تمام `qid2`های فایل `train` فضای جستجوی شما می‌باشد، توجه کنید که باید مقادیر یکتای این ستون را برای جستجو در نظر بگیرید.

مجموعه دادگان

ویژگی	توضیحات
<code>ID</code>	شماره یکتای پرس‌وجو
<code>qid1</code>	آیدی سوال اول
<code>qid2</code>	آیدی سوال دوم
<code>Question1</code>	متن سوال اول
<code>Question2</code>	متن سوال دوم
<code>is_duplicate</code>	برچسب <i>paraphrase</i>

بخش دوم – بازیابی با استفاده از بردارهای معنایی (۲۵ امتیاز)

با استفاده از مدل *BERT* متن سوالات `qid2` از فایل `train` را در فضای برداری بازنمایی کنید. سپس با استفاده از معیار فاصله‌ی کسینوسی^۲، ۱۰ سوال مشابه با سوالات موجود در ستون `qid1` فایل `test` را با توجه به بردارهای استخراج شده از فایل `train` بدست بیاورید.

^۱ Dataset

^۲ Cosine Similarity

بخش سوم - بازیابی با آموزش مدل شبکه عصبی (۴۵ امتیاز)

در این بخش باید با طراحی یک شبکه Siamese مدلی مبتنی بر شبکه عصبی را برای بازیابی سوالات آموزش دهید. برای آموزش مدل از داده‌های موجود در فایل *train* و *validation* استفاده نمایید. سپس برای هر سوال موجود در ستون *qid1* فایل *test*، ۱۰ سوال با بیشترین شباهت را از فایل *train* بدست بیاورید.

* برای طراحی شبکه عصبی موردنظر آزاد هستید و می‌توانید از ساختارهای پیشنهادی زیر استفاده کنید:

- ورودی شبکه بازنمایی *word2vec* یا *fasttext* کلمات باشد.
- لایه‌های شبکه با مدل‌های *LSTM* یا *BiLSTM* باشد.
- ترکیب انتهای شبکه برای مقایسه دو متن فاصله کسینوسی باشد و یا کانکت دو بردار به یک لایه شبکه عصبی ساده داده شود.
- سعی کنید با تست کردن حالت‌های مختلف ذکر شده بهترین نتیجه را بدست آورید.

بخش چهارم - کار با روش‌های ارزیابی (۳۰ امتیاز)

هر سه روش مطرح شده در بالا را با استفاده از معیارهای ارزیابی *P@10*، *P@5*، *MAP* و *MRR* ارزیابی و گزارش کنید. هر سه روش مورد نظر را باید پیاده‌سازی کنید.

* برای محاسبه معیار ارزیابی از ستون *qid2* فایل تست به عنوان برچسب درست استفاده کنید، در واقع شما به ازای هر سوال در ستون *qid1* فایل تست، تمام سوالات مشابهی که بازگردانده می‌شوند، اگر در ستون *qid2* بود، به عنوان پاسخ صحیح لحاظ شود و اگر در این ستون نبود به عنوان پاسخ نادرست در نظر گرفته شود.

* با توجه به این که تعداد کل سوالات مرتبط برای هر سوال در فایل *test* مشخص شده است، بنابراین برای محاسبه‌ی معیار *AP* مخرج کسر را برابر با تعداد کل سوالات مرتبط در فایل *test* قرار دهید.

بخش آخر - برخی نکات در مورد گزارش و تمرین

- دادگان مطرح شده در این تمرین و تمامی بخش‌ها همراه با صورت تمرین در سایت درس قرار داده شده است.
- در این تمرین شما مجاز به استفاده کتابخانه‌های زیر و موارد مشابه و هم‌کاربرد با آن‌ها می‌باشد:
`numpy, scipy, pandas, genism, pickle, tensorflow, pytorch, keras`
- در این تمرین سعی شده است علاوه بر آشنایی شما با کاربرد مباحث ارائه شده در کلاس و لمس بهتر آن، خلاقیت و حل چالش شما نیز ارزیابی شود. لذا در صورتی که در این تمرین چالشی وجود دارد که شما راه حلی برای آن ارائه دادید و استفاده کردید، آن را در گزارش بیان کنید. اما اگر مشکلی بزرگ وجود دارد که نیاز به بررسی مجدد دارد، آن را از طریق ایمیل با تدریس‌یاران درس مطرح کنید.
- در صورتی که هر گونه پیش‌پردازش بر روی دادگان انجام دادید آن را در گزارش خود بیان کنید.
- این تمرین ۱ نمره از بارم کلی شما از تمرینات را با توجه به پوشش مباحث و حجم تمرین دارد. امتیاز این تمرین از ۱۰۰ محاسبه می‌شود که بارم هر بخش مشخص شده است.
- در تمامی بخش‌ها، میزان نتایج شما در ارزیابی شما تاثیر چندانی ندارند (مگر اینکه بسیار دور باشد). بلکه میزان تسلط، دیدگاه و پیاده‌سازی، تحلیل‌ها و خلاقیت شماست که در نمره شما تاثیر مستقیم دارد و بر اساس این موارد مورد ارزیابی قرار می‌گیرد.

موفق باشید - درویشی